

# Praca domowa 5

## Miary odległości

Damian Jankowski s188597

20 maja 2023

## 1 Wstęp

Celem pracy domowej było zapoznanie się z wybranymi miarami odległości. Miary odległości odgrywają ważną rolę w uczeniu maszynowym. Są one wykorzystywane do obliczania odległości między obserwacjami w celu klasyfikacji nowych danych. W zależności od wybranej miary, wyniki mogą się znacznie różnić. Dlatego też ważne jest, aby wybrać miarę odpowiednią do danego problemu.

Dla przykładowych danych należało obliczyć odległości następującymi miarami:

- miejska (Manhattan)
- euklidesowa
- Czebyszewa

Każda z tych miar jest rozszerzeniem tzw. odległości Minkowskiego, która jest zdefiniowana następująco:

$$L_m(x, y) = \left( \sum_{i=1}^n |x_i - y_i|^m \right)^{\frac{1}{m}} \quad (1)$$

gdzie:

- $x, y$  - wektory danych
- $n$  - liczba wymiarów
- $m$  - parametr miary

### 1.1 Odległość miejska (Manhattan)

Szczególny przypadek odległości Minkowskiego, dla  $m = 1$ , wyrażona wzorem:

$$L_1(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (2)$$

Daje podobne wyniki jak odległość euklidesowa, ale odstające wartości są stłumione przez brak podnoszenia ich do kwadratu.

### 1.2 Odległość euklidesowa

Jest to odległość Minkowskiego dla  $m = 2$ , wyrażona wzorem:

$$L_2(x, y) = \sqrt{\sum_{i=1}^n |x_i - y_i|^2} \quad (3)$$

Najczęściej wykorzystywana miara odległości. Wadą tej miary jest duża wrażliwość na wartości odstające z racji kwadratowego wykładnika.

### 1.3 Odległość Czebyszewa

Wyrażona wzorem:

$$L_{\infty}(x, y) = \max_{i=1}^n |x_i - y_i| = \lim_{m \rightarrow \infty} L_m(x, y) \quad (4)$$

Wprowadzona przez Pafnutija Czebyszewa. Jest to szczególny przypadek odległości Minkowskiego, dla  $m = \infty$ . Wartość odległości jest równa największej różnicy między wartościami wektorów.

W szachach odległość Czebyszewa jest równa liczbie ruchów króla, potrzebnych do przejścia z jednego pola na drugie.

## 2 Zadanie

Do przećwiczenia wyznaczania tych miar wybrałem przykładowy zbiór danych:

$$X = \begin{bmatrix} -3.5 \\ 4.4 \\ -2.2 \end{bmatrix} \quad Y = \begin{bmatrix} 0.1 \\ -2.5 \\ 3.9 \end{bmatrix} \quad (5)$$

Obliczenia prezentuję poniżej:

Handwritten calculations on a grid background:

$$X = \begin{bmatrix} -3,5 \\ 4,4 \\ -2,2 \end{bmatrix} \quad Y = \begin{bmatrix} 0,1 \\ -2,5 \\ 3,9 \end{bmatrix} \quad L_m = \left( \sum_{i=1}^n |x_i - y_i|^m \right)^{\frac{1}{m}}$$

Odległość miejska (Manhattan):

$$L_1 = |-3,5 - 0,1| + |4,4 - (-2,5)| + |-2,2 - 3,9| = 3,6 + 6,9 + 6,1 = 16,6$$

Odległość euklidesowa:

$$L_2 = \sqrt{(-3,5 - 0,1)^2 + (4,4 - (-2,5))^2 + (-2,2 - 3,9)^2} = \sqrt{12,96 + 47,61 + 37,21} \approx 9,89$$

Odległość Czebyszewa:

$$L_{\infty} = \max(3,6; 6,9; 6,1) = 6,9$$

By sprawdzić poprawność obliczeń napisałem krótki skrypt w języku Python:

```
X = [ -3.5, 4.4, -2.2 ]
Y = [ 0.1, -2.5, 3.9 ]

def manhattan_distance(x, y):
    return sum(abs(a - b) for a, b in zip(x, y))

def euclidean_distance(x, y):
    return round(sum((a - b) ** 2 for a, b in zip(x, y)) ** .5, 2)

def chebyshev_distance(x, y):
    return max(abs(a - b) for a, b in zip(x, y))

print("Manhattan distance: ", manhattan_distance(X, Y))
print("Euclidean distance: ", euclidean_distance(X, Y))
print("Chebyshev distance: ", chebyshev_distance(X, Y))
```

Wynik działania programu:

```
Manhattan distance:  16.6
Euclidean distance:  9.89
Chebyshev distance:  6.9
```